MCAD : Un masque contextuel pour relier les requêtes OLAP aux objectifs stratégiques de l'organisation

Habib Benaouda, Sidi Mohamed Benslimane, Zohra Slama

***Résumé*—Les entrepôts de données et les systèmes OLAP constituent aujourd'hui une infrastructure centrale pour le pilotage stratégique, mais la plupart des plates-formes exécutent encore les requêtes analytiques sans expliciter leur contribution réelle aux objectifs métier. Les approches de personnalisation et de recommandation OLAP restent centrées sur les profils et l'historique des utilisateurs [4]–[6], tandis que les systèmes sensibles au contexte et les graphes de connaissances modélisent partiellement l'environnement décisionnel [7]–[10], [12], [13]. Aucun de ces cadres n'offre toutefois un mécanisme formel permettant de mesurer, requête par requête et session par session, dans quelle mesure une requête OLAP contribue effectivement à l'atteinte d'un objectif stratégique donné.**

Le *Masque Contextuel de l'Analyse Décisionnelle* (MCAD) est proposé pour combler cette lacune. Il modélise le contexte d'analyse sous la forme d'un graphe de connaissances contextuelles (CKG) reliant dimensions, mesures, KPI, contraintes et scénarios ; représente l'objectif stratégique global comme un ensemble de contraintes ancrées dans ce graphe via des nœuds virtuels décrivant les cellules analytiques nécessaires à leur calcul ; abstrait chaque requête analytique en un plan de requête ; vérifie sa validité contextuelle au moyen d'un prédicat explicable ; et quantifie, pour chaque requête et chaque session, un taux de contribution à l'atteinte totale ou partielle de l'objectif. Le MCAD établit ainsi un pont explicite entre objectifs analytiques (requêtes OLAP) et objectifs métier, en filtrant les requêtes non contributives et en fournissant des indicateurs de progression vers l'objectif.

***Index Terms*—Entrepôts de données, OLAP, Business Intelligence, objectifs stratégiques, graphe de connaissances contextuelles, KPI, contraintes métier, optimisation contextuelle, personnalisation.**

I. Introduction

Les entrepôts de données et les systèmes OLAP constituent l'ossature de nombreux dispositifs décisionnels contemporains [1]–[3]. Ils offrent un cadre multidimensionnel pour agréger des faits, explorer des hiérarchies de dimensions et alimenter tableaux de bord et rapports destinés aux décideurs. La littérature en Business Intelligence (BI) et en *analytics* a largement étudié la modélisation dimensionnelle, les processus ETL, les langages de requêtes et l'intégration de données hétérogènes à grande échelle [1]–[3].

Malgré cette maturité, une question reste étonnamment peu adressée : comment relier explicitement les requêtes analytiques soumises au système aux objectifs métier ou stratégiques qu'elles sont censées servir. En pratique, les analystes enchaînent des requêtes OLAP sophistiquées ; l'impact stratégique de ces requêtes reste cependant implicite, évalué *a posteriori* et fortement dépendant de l'expertise humaine. Un système peut répondre de manière exacte à une requête parfaitement formulée tout en n'apportant aucune information réellement utile au regard de l'objectif de l'analyse.

De nombreuses contributions ont cherché à rendre les environnements décisionnels plus adaptatifs. Les approches de personnalisation et de recommandation OLAP adaptent schémas, vues et requêtes aux profils, rôles, préférences ou historiques de navigation des utilisateurs [4]–[6]. Les systèmes de recommandation sensibles au contexte intègrent des variables contextuelles – temps, localisation, dispositif, tâche – dans la fonction de score [12], [13]. Parallèlement, les graphes de connaissances et les modèles sémantiques d'indicateurs structurent la connaissance métier et les KPI [7]–[10], tandis que les travaux sur l'optimisation contextuelle pour la décision sous incertitude proposent de nouvelles manières d'articuler apprentissage et optimisation [11]. Ces approches posent des jalons importants, mais aucune ne fournit un cadre unifié permettant de dire, pour une requête donnée : *« dans quelle mesure cette requête contribue-t-elle réellement à l'objectif stratégique visé ? »*

Le *Masque Contextuel de l'Analyse Décisionnelle* (MCAD) est introduit précisément pour répondre à cette question. Le modèle repose sur cinq idées clés :

- modéliser le contexte d'analyse décisionnelle sous la forme d'un graphe de connaissances contextuelles (CKG) qui encode dimensions, niveaux, mesures, KPI, unités, contraintes, scénarios et fenêtres temporelles ;
- représenter l'objectif stratégique global de l'organisation comme un ensemble explicite de contraintes analytiques reliées au CKG par des nœuds virtuels décrivant les cellules minimales nécessaires à leur calcul ;
- abstraire chaque requête OLAP (quelle que soit sa syntaxe) en un plan de requête structuré décrivant fait, grain, mesures, agrégateurs, unités, filtres et fenêtre temporelle ;
- vérifier la validité contextuelle de ce plan par un prédicat fondé sur le CKG, capable de justifier chaque invalidation ;
- définir des mesures de contribution stratégique qui quantifient la part des contraintes de l'objectif rendues calculables par la requête et la progression d'une session d'analyse vers cet objectif.

Les principales contributions de cet article sont les suivantes :

- nous proposons un **cadre conceptuel** pour la mo-

Les auteurs sont avec le Département d'Informatique, Université Djillali Liabès, Sidi Bel Abbès, Algérie. (Coordonnées à adapter selon les exigences de la revue.)

délisation du contexte d'analyse via un CKG et la représentation d'un objectif stratégique global O sous la forme d'un ensemble de contraintes analytiques ;
— nous introduisons une **formalisation mathématique** du MCAD, incluant le prédicat de validité contextuelle $\mathrm{SAT}(QP)$, les ensembles $\mathrm{Real}(QP)$ et $C_{\mathrm{eval}}(QP, O)$, et une famille de **mesures de contribution** $\varphi(QP, O)$ et $\varphi^{\leq t}(O)$, dont nous établissons plusieurs propriétés ;
— nous décrivons une **architecture d'implémentation** du MCAD, détaillons une **étude de cas** basée sur un schéma de type FoodMart, et présentons une **validation expérimentale** sur des workloads synthétiques inspirés de ce benchmark ;
— nous discutons enfin la **construction et la maintenance du CKG**, la **complexité algorithmique** des principales opérations, la **portabilité** du MCAD au-delà de MDX vers d'autres langages analytiques, et le **workflow d'interaction** entre analyste et MCAD.

La suite de l'article est organisée comme suit. La Section II présente les travaux connexes et positionne le MCAD. La Section III propose une vue d'ensemble du modèle. La Section IV développe la formalisation mathématique. La Section V décrit l'architecture d'implémentation et le workflow utilisateur. La Section VI illustre le modèle sur une étude de cas et des scénarios d'analyse. La Section VII détaille la validation expérimentale et l'analyse des performances. La Section VIII discute les apports, limites et perspectives, et la Section IX conclut.

II. Travaux connexes

Les contributions du MCAD se situent à l'intersection de plusieurs axes de recherche : (i) entrepôts de données et OLAP, (ii) personnalisation et recommandation OLAP, (iii) systèmes de recommandation sensibles au contexte, (iv) graphes de connaissances et modèles sémantiques d'indicateurs, et (v) optimisation contextuelle pour la décision.

Les travaux fondateurs sur les entrepôts de données et l'OLAP se concentrent sur la modélisation multidimensionnelle (schémas étoile et flocon), les hiérarchies de dimensions, les opérations d'agrégation et l'optimisation des requêtes analytiques [1], [2]. Ils ont rendu opérationnelle la vision du *cube* : des faits observés à un grain donné, agrégés le long de dimensions, interrogés via des langages comme MDX. La littérature en BI et analytics met ensuite l'accent sur l'intégration de données massives, les outils d'analyse et les tableaux de bord pour soutenir la décision managériale [3]. Dans ces cadres, le contexte d'analyse (contraintes métier, scénarios, règles d'agrégation, unités admissibles) demeure toutefois dispersé dans des métadonnées ou des documents, sans être pleinement formalisé dans une structure exploitable pour valider et expliquer les requêtes.

Un deuxième axe concerne la personnalisation des entrepôts de données et l'adaptation de l'OLAP aux utilisateurs. Des synthèses détaillent comment profils, rôles, préférences ou historiques de navigation peuvent être exploités pour adapter schémas, vues et interfaces [4]. D'autres travaux introduisent la personnalisation dès la modélisation conceptuelle [5] ou recommandent des sessions et des requêtes OLAP via des techniques de filtrage collaboratif [6]. Ces approches visent une notion de pertinence centrée sur l'utilisateur : proposer des vues conformes à ses préférences ou à celles d'utilisateurs similaires. Elles ne cherchent pas à mesurer la contribution des requêtes à un objectif stratégique formellement défini. Le MCAD adopte une perspective complémentaire : il place l'objectif métier/stratégique au centre, comme un ensemble de contraintes ancrées dans le CKG, et évalue chaque requête à l'aune de sa capacité à rendre ces contraintes calculables.

Les systèmes de recommandation sensibles au contexte (Context-Aware Recommender Systems, CARS) prolongent la personnalisation en intégrant des variables contextuelles (temps, localisation, dispositif, tâche, situation) dans la fonction de score [12], [13]. Dans le domaine décisionnel, des travaux sur l'OLAP sensible au contexte montrent que l'exploitation de ces variables permet de filtrer ou repondérer dynamiquement les faits [12]. Dans la plupart de ces modèles, le contexte est représenté comme un vecteur d'attributs ou un ensemble de métadonnées. Le MCAD transpose cette sensibilité au contexte dans un cadre symbolique : le contexte n'est plus un simple vecteur, mais un graphe structuré où les liens entre dimensions, mesures, KPI, contraintes, unités et scénarios sont explicitement modélisés.

Les graphes de connaissances constituent un troisième pilier du positionnement du MCAD. Des synthèses récentes définissent et analysent les pratiques de modélisation des *knowledge graphs* pour représenter entités, schémas et relations dans des graphes typés [7]. Dans le domaine de la performance, d'autres travaux répertorient les modèles sémantiques d'indicateurs, leurs liens avec les objectifs stratégiques et les besoins en termes de validation [8]–[10]. Ces travaux convergent vers l'idée que les KPI doivent être ancrés dans un modèle sémantique explicite. Le MCAD s'inscrit dans cette lignée en représentant, dans un CKG, dimensions, mesures, KPI et contraintes, mais aussi des nœuds virtuels décrivant les cellules analytiques nécessaires. Ce graphe sert ensuite de support au prédicat de validité contextuelle et à la fonction de calculabilité des contraintes.

Enfin, les travaux sur l'optimisation contextuelle pour la décision sous incertitude [11] et la décision multicritère [14], ainsi que les modèles de bandits contextuels [15], [16], fournissent des cadres généraux pour modéliser des décisions dépendantes d'un contexte, combinant plusieurs critères ou optimisant une récompense cumulative. Ils ne visent pas directement l'OLAP, mais inspirent la manière dont le MCAD exploite sa mesure de contribution et son gain marginal au fil d'une session : ces quantités peuvent être interprétées comme une récompense explicable et servir à ordonner ou recommander des requêtes apportant le plus de couverture additionnelle des contraintes de l'objectif.

A. Positionnement synthétique du MCAD

Contrairement aux systèmes centrés sur l'utilisateur, MCAD place l'objectif stratégique au cœur du dispositif, et, contrairement aux travaux sur les KPI sémantiques, il introduit une mesure explicite de contribution des requêtes analytiques à ces objectifs.

TABLE I
POSITIONNEMENT DE MCAD PAR RAPPORT À DES APPROCHES REPRÉSENTATIVES.

Approche	Centré utilisateur	Centré objectif	Représentation du contexte	Validation contextuelle	Mesure stratégique
Personnalisation OLAP [4], [5]	Oui	Non	Profil / métadonnées	Non	Non
Recommandation OLAP [6]	Oui	Non	Historique de sessions	Non	Non
OLAP sensible au contexte [12]	Partiel	Non	Attributs contextuels	Limitée	Non
Graphes de connaissances / KPI sémantiques [7]–[10]	Non	Partiel	Graphe / ontologie	Oui (KPI)	Non
MCAD (proposé)	Non (centré objectif)	Oui	CKG riche	Oui, explicable	Oui (φ)

III. VUE D'ENSEMBLE DU MCAD

À un niveau macro, le MCAD peut être vu comme une couche sémantique interposée entre l'utilisateur analytique et l'entrepôt de données. Son rôle est double : (i) contrôler la cohérence des requêtes au regard du contexte, et (ii) mesurer leur utilité stratégique par rapport à des objectifs formellement spécifiés.

A. Chaîne conceptuelle requête → objectif

B. Composants principaux

Le *graphe de connaissances contextuelles* (CKG) rassemble, dans une structure unique, les dimensions et niveaux de l'entrepôt, les mesures et KPI, les unités, les contraintes métier, les scénarios d'analyse et les fenêtres temporelles, ainsi que les relations qui les lient. Il sert de « carte » des possibilités analytiques, où les règles de résumabilité, de compatibilité d'unités, de validité des agrégations et de cohérence des filtres sont explicitement représentées.

L'objectif stratégique global de l'organisation est modélisé comme un ensemble fini de contraintes portant sur des KPI identifiés (par exemple marge, taux de rupture, délai de livraison). Chaque contrainte exprime une exigence quantifiable (seuils, tendances, comparaisons) et est reliée à des éléments du CKG. Pour chaque contrainte, le MCAD identifie les « cellules analytiques » minimales nécessaires à son évaluation : combinaisons de fait, de niveaux, de mesures, d'agrégateurs, d'unités, de filtres et de période. Ces cellules sont modélisées sous forme de *nœuds virtuels*.

Toute requête OLAP est traduite en *plan de requête* qui en capture les éléments essentiels : table de faits ciblée, grain, mesures et agrégateurs, unités, filtres et fenêtre temporelle. Cette représentation abstraite permet de raisonner de manière uniforme sur des requêtes de complexité variée, indépendamment de leur syntaxe (MDX, SQL analytique, DAX, etc.). Un prédicat de validité contextuelle exploite le CKG pour vérifier si le plan est cohérent avec le contexte ; en cas de non-satisfaction, le MCAD identifie la règle violée et peut fournir une justification.

Une fois la requête jugée contextuellement valide, le MCAD détermine quels nœuds virtuels associés à l'objectif deviennent réalisables grâce à cette requête, et en déduit quelles contraintes deviennent calculables. La notion de *masque contextuel* capture alors la partie du plan réellement utile pour l'objectif. La contribution stratégique est mesurée par un taux de couverture des contraintes, éventuellement pondéré par leur importance. À l'échelle d'une session d'analyse, le MCAD agrège les contraintes progressivement couvertes par les requêtes successives et fournit des indicateurs de progression vers l'objectif, ainsi qu'une identification des requêtes sans gain marginal.

C. Extrait de CKG

La Figure 2 montre un extrait simplifié de CKG centrée sur une dimension, une mesure, un KPI, une contrainte et un nœud virtuel.

D. Construction pratique du CKG

En pratique, la construction du CKG s'appuie sur plusieurs sources :

- le schéma multidimensionnel existant (tables de faits, dimensions, hiérarchies, mesures) ;
- les métadonnées techniques (dictionnaires de données, règles ETL, contraintes d'intégrité) ;
- la documentation métier (définitions de KPI, règles de calcul, procédures de reporting) ;
- des ateliers avec des experts métier pour expliciter des règles implicites (incompatibilités de filtres, scénarios, unités autorisées).

Une première version du CKG peut être générée automatiquement à partir du schéma et des métadonnées, puis enrichie et validée lors de ces ateliers. D'un point de vue technologique, le CKG peut être stocké dans une base de graphes (par exemple de type *property graph*) ou dans un triple store RDF, ce qui facilite les requêtes de *pattern matching* nécessaires aux vérifications de validité contextuelle et au calcul de $\mathrm{Real}(QP)$.

IV. FORMALISATION DU MODÈLE MCAD

Cette section présente les principaux objets formels du MCAD. Nous introduisons le contexte multidimensionnel et le CKG, la représentation des objectifs stratégiques, la notion de nœuds virtuels et de plans de requête, le prédicat de validité contextuelle et les mesures de contribution. Nous énonçons ensuite quelques propriétés de base et illustrons la formalisation par un exemple chiffré. Les preuves détaillées sont reportées en Annexe A.

A. Contexte multidimensionnel

On considère un entrepôt de données structuré selon un schéma multidimensionnel classique [1], [2], comprenant un ensemble de tables de faits F, un ensemble de dimensions D organisées en hiérarchies de niveaux, et un ensemble de mesures M. Pour une dimension $D \in D$, on note $L(D)$ l'ensemble de

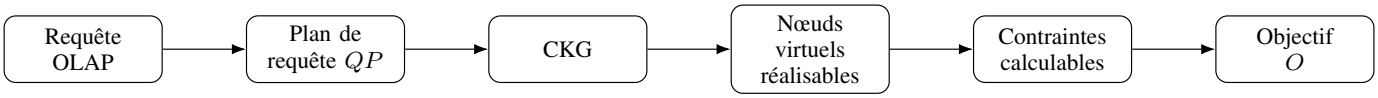

FIGURE 1. Chaîne conceptuelle de traitement dans le MCAD.

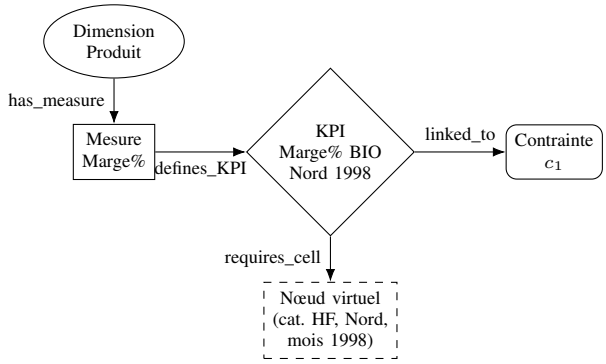

FIGURE 2. Extrait simplifié de CKG liant dimension, mesure, KPI, contrainte et nœud virtuel.

TABLE II
PRINCIPALES NOTATIONS DU MODÈLE MCAD.

Symbole	Description
F	Ensemble des tables de faits
D	Ensemble des dimensions
$L(D)$	Niveaux d'une dimension D
g	Grain d'analyse (produit de niveaux)
M	Ensemble des mesures et KPI
CKG	Graphe de connaissances contextuelles
O	Objectif stratégique global
$C^*(O)$	Ensemble de contraintes de O
$N(c)$	Nœuds virtuels associés à c
QP	Plan abstrait d'une requête
$\mathrm{Real}(QP)$	Nœuds virtuels réalisables par QP
$C_{\mathrm{eval}}(QP, O)$	Contraintes calculables via QP
$\varphi(QP, O)$	Contribution de QP à O

ses niveaux hiérarchiques. Un *grain d'analyse* est un produit cartésien de niveaux :

$$g = \prod_{D \in D_g} \ell_D, \quad \ell_D \in L(D),$$

où $D_g \subseteq D$ est l'ensemble des dimensions présentes au grain g.

Une *entité analytique élémentaire* est un triplet (f, g, m) où $f \in F$ est une table de faits, g un grain et m une mesure ou un KPI dérivé calculé à ce grain.

Le Tableau II résume quelques notations clés utilisées dans la suite.

B. Graphe de connaissances contextuelles

Le contexte d'analyse est représenté par un graphe de connaissances contextuelles

$$\mathrm{CKG} = (V, E, L),$$

où V est un ensemble de nœuds, $E \subseteq V \times L \times V$ un ensemble d'arêtes étiquetées, et L l'ensemble des types de relations. Les nœuds représentent notamment :

— des éléments de schéma (dimensions, niveaux, membres, mesures, KPI) ;
— des objets de calcul (unités, agrégateurs, opérateurs) ;
— des éléments métier (contraintes, scénarios, fenêtres temporelles).

Les arêtes sont étiquetées par des relations telles que *rolls_up_to*, *has_measure*, *defines_KPI*, *uses_unit*, *allowed_agg*, *requires_grain*, *conflicts_with*, *applicable_in_scenario*, etc. [7]–[10]. Les règles de calcul des KPI et les contraintes métier sont codées sous forme de nœuds et d'arêtes additionnels.

C. Objectifs stratégiques et contraintes

Un objectif stratégique global est modélisé comme un couple

$$O = (K^*(O), C^*(O)),$$

où $K^*(O)$ est l'ensemble des KPI pertinents pour l'objectif, et $C^*(O)$ un ensemble fini de contraintes analytiques. Chaque contrainte $c \in C^*(O)$ est associée à un KPI $\mathrm{KPI}(c) \in K^*(O)$ et à un prédicat r_c qui, appliqué à un ensemble approprié d'entités analytiques, renvoie une valeur booléenne (satisfaite/non satisfaite) ou un degré de satisfaction dans $[0, 1]$. Le MCAD distingue la *calculabilité* d'une contrainte (possibilité de calculer la quantité nécessaire à son évaluation) et sa *satisfaction* effective sur les données.

D. Nœuds virtuels

Pour relier les contraintes à la structure de l'entrepôt, le MCAD introduit des *nœuds virtuels* :

$$nv = (f, g, m, \alpha, u, S, w),$$

où $f \in F$ est une table de faits, g un grain, $m \in M$ une mesure ou un KPI, α un opérateur d'agrégation, u une unité, S un ensemble de filtres (conditions sur des membres de dimensions) et w une fenêtre temporelle. Intuitivement, un nœud virtuel décrit une « cellule analytique » minimale, caractérisée par :

— une position dans le cube (grain g, filtres S, fenêtre w) ;
— une quantité observée ou dérivée (mesure m, agrégateur α, unité u).

Pour chaque contrainte $c \in C^*(O)$, on suppose donné un ensemble fini $N(c)$ de nœuds virtuels nécessaires à son calcul. On pose

$$N(O) = \bigcup_{c \in C^*(O)} N(c).$$

Exemple chiffré de nœud virtuel: Considérons le nœud virtuel suivant, lié à la contrainte de marge sur la gamme BIO en région Nord :

$$nv_1 = (\textit{VENTES}, g, \mathrm{Marge\%}, \mathrm{avg}, \%, S, w),$$

où g fixe le grain {Mois=2024-03, Gamme=BIO, Région=Nord}, S = {Canal = Magasin physique} et w =

TABLE III
EXEMPLES DE RELATIONS ENTRE SLICERS DANS LE CKG.

Relation	Interprétation	Exemple
`mutex`	Combinaison interdite	*Canal=Online* & *Magasin=Physique*
`includes`	B inclut A	*Région=Nord* inclut *Ville=Lille*
`coherent`	Combinaison autorisée	*Gamme=BIO* & *Promo=Oui*

$[2024\text{-}03\text{-}01, 2024\text{-}03\text{-}31]$. Si, dans l'entrepôt, la marge% moyenne observée pour cette cellule est 18,7%, le nœud virtuel nv_1 représente conceptuellement cette cellule analytique (position + mesure), indépendamment du langage de requête utilisé pour l'obtenir.

E. Plans de requête

Toute requête analytique est abstraite en un *plan de requête*

$$QP = (f_Q, g_Q, M_Q, \alpha_Q, u_Q, S_Q, w_Q),$$

qui capture la table de faits ciblée f_Q, le grain g_Q, l'ensemble des mesures M_Q, les agrégateurs α_Q, les unités u_Q, les filtres S_Q et la fenêtre temporelle w_Q. Cette abstraction est construite en analysant la requête (MDX, SQL analytique, DAX, etc.) et en reliant ses composants au CKG. Le MCAD ne dépend donc pas d'un langage particulier, mais uniquement de la possibilité d'extraire un tel plan.

F. Validité contextuelle et relations entre slicers

La validité contextuelle d'un plan QP est capturée par un prédicat

$$\begin{aligned}\mathrm{SAT}(QP) \Leftrightarrow \mathrm{grain_ok}(QP) \wedge \mathrm{agg_ok}(QP) \wedge \mathrm{unit_ok}(QP) \\ \wedge\, \mathrm{slc_ok}(QP) \wedge \mathrm{time_ok}(QP) \wedge \mathrm{nvac_ok}(QP).\end{aligned} \tag{1}$$

où chaque clause encode une famille de contraintes issues du CKG :

- grain_ok vérifie la compatibilité du grain avec les hiérarchies de dimensions et les règles de résumabilité ;
- agg_ok vérifie que les agrégateurs demandés sont autorisés pour les mesures considérées (*allowed_agg*) ;
- unit_ok vérifie la cohérence des unités (pas de mélange de devises sans conversion, etc.) ;
- slc_ok vérifie la non-contradiction et la compatibilité des filtres ;
- time_ok vérifie la cohérence temporelle (périodes comparables, fenêtres valides) ;
- nvac_ok vérifie que le sous-espace interrogé n'est pas *a priori* vide selon le CKG (absence de combinaisons explicitement impossibles).

Les relations entre slicers dans le CKG (par exemple `mutex`, `includes`, `coherent`) sont particulièrement importantes pour slc_ok. Le Tableau III illustre trois types de relations typiques.

La clause $\mathrm{slc_ok}(QP)$ exploite ces relations : si deux slicers sont reliés par `mutex`, la combinaison est rejetée ; si un slicer en inclut un autre, l'algorithme peut simplifier ou normaliser le filtre ; les relations `coherent` servent à valider explicitement certaines combinaisons métier.

Algorithm 1 Vérification de la validité contextuelle $\mathrm{SAT}(QP)$

Require: Plan de requête QP, graphe CKG
Ensure: $\mathrm{SAT}(QP) \in \{\texttt{vrai}, \texttt{faux}\}$

```
Extraire (f_Q, g_Q, M_Q, α_Q, u_Q, S_Q, w_Q) de QP
if grain_ok(QP, CKG) est faux then
    return faux
end if
if agg_ok(QP, CKG) est faux then
    return faux
end if
if unit_ok(QP, CKG) est faux then
    return faux
end if
if slc_ok(QP, CKG) est faux then
    return faux
end if
if time_ok(QP, CKG) est faux then
    return faux
end if
if nvac_ok(QP, CKG) est faux then
    return faux
end if
return vrai
```

L'algorithme 1 donne une version simplifiée du calcul de $\mathrm{SAT}(QP)$.

G. Nœuds réalisables et contraintes calculables

Étant donné un objectif O et un plan QP, l'ensemble des nœuds virtuels de $N(O)$ réalisables par QP est noté

$$\mathrm{Real}(QP) \subseteq N(O),$$

et défini via une procédure **IsRealizable** qui interroge le CKG pour vérifier la compatibilité entre $(f_Q, g_Q, M_Q, \alpha_Q, u_Q, S_Q, w_Q)$ et les paramètres $(f, g, m, \alpha, u, S, w)$ de chaque nœud virtuel. On impose notamment que :

- $f_Q = f$ ou f_Q est reliée à f par une relation de raffinement compatible ;
- g_Q est au moins aussi détaillé que g dans chaque dimension pertinente ;
- les filtres et fenêtres sont compatibles (par exemple $S \subseteq S_Q$, $w \subseteq w_Q$ ou relations analogues).

L'ensemble des contraintes rendues calculables par QP est alors

$$C_{\mathrm{eval}}(QP, O) = \{\, c \in C^*(O) \mid N(c) \cap \mathrm{Real}(QP) \neq \emptyset \,\}.$$

Le *masque contextuel* induit par QP pour O est

$$S^*(QP, O) = \bigcup_{c \in C_{\mathrm{eval}}(QP,O)} \big(N(c) \cap \mathrm{Real}(QP)\big).$$

H. Mesures de contribution

Pour un objectif O tel que $|C^*(O)| \geq 1$, la contribution non pondérée de QP à O est définie par

$$\varphi(QP, O) = \frac{|C_{\mathrm{eval}}(QP, O)|}{|C^*(O)|} \in [0, 1].$$

Une variante pondérée utilise des poids $w_c > 0$:

$$\varphi_w(QP, O) = \frac{\sum_{c \in C_{\text{eval}}(QP,O)} w_c}{\sum_{c \in C^*(O)} w_c}.$$

Pour une session de requêtes $(QP_1, \ldots, QP_T)$, on définit

$$C_{\text{eval}}^{\leq t}(O) = \bigcup_{i=1}^{t} C_{\text{eval}}(QP_i, O), \quad \varphi^{\leq t}(O) = \frac{|C_{\text{eval}}^{\leq t}(O)|}{|C^*(O)|},$$

et le gain marginal $\Delta\varphi_t = \varphi^{\leq t}(O) - \varphi^{\leq t-1}(O)$.

I. Propriétés de base et complexité

Nous rappelons quelques propriétés simples (preuves en Annexe A).

Proposition 1. *Pour tout objectif O et tout plan QP tels que $|C^*(O)| \geq 1$, on a $\varphi(QP, O) \in [0, 1]$. De plus :*

- *$\varphi(QP, O) = 0$ si et seulement si $C_{\text{eval}}(QP, O) = \emptyset$;*
- *$\varphi(QP, O) = 1$ si et seulement si $C_{\text{eval}}(QP, O) = C^*(O)$.*

Proposition 2. *Soient QP_a et QP_b deux plans de requête et O un objectif. Si $\text{Real}(QP_a) \subseteq \text{Real}(QP_b)$, alors $\varphi(QP_a, O) \leq \varphi(QP_b, O)$.*

Proposition 3. *Pour une session $(QP_1, \ldots, QP_T)$, la suite $(\varphi^{\leq t}(O))_{t=1,\ldots,T}$ est monotone croissante et bornée dans $[0, 1]$. En particulier, $\Delta\varphi_t \geq 0$ pour tout t.*

En termes de complexité, dans une implémentation naïve, le calcul de $\text{Real}(QP)$ est en $O(|N(O)| \cdot c_{\text{ckg}})$, où c_{ckg} représente le coût moyen d'une vérification de compatibilité dans le CKG. En indexant les nœuds par type et par identifiant de dimension/mesure, ce coût peut être amorti vers des temps presque constants pour les motifs locaux. Le calcul de $C_{\text{eval}}(QP, O)$ est linéaire en $|C^*(O)|$ si l'on dispose d'une structure indexant les $N(c)$. Le surcoût introduit par le MCAD reste ainsi linéaire dans la taille pertinente du CKG et du modèle d'objectif, ce qui est compatible avec un usage interactif.

J. Portabilité vers d'autres langages de requête

Le MCAD ne dépend pas d'un langage de requête particulier, mais uniquement de la capacité à extraire d'une requête un plan abstrait $QP = (f_Q, g_Q, M_Q, \alpha_Q, u_Q, S_Q, w_Q)$. Dans le cas de MDX, cette extraction repose sur l'analyse des axes, des membres de dimensions et des fonctions d'agrégation. Dans un contexte SQL analytique, le même plan est dérivé à partir des clauses `FROM`, `WHERE`, `GROUP BY` et des fonctions d'agrégation de la clause `SELECT`. Des langages comme DAX peuvent être traités de manière analogue, à condition de disposer d'une transformation vers un plan explicite de type (fait, grain, mesures, filtres, période). Le MCAD fournit donc un cadre conceptuel indépendant du langage, dès lors que ce langage peut être ramené à cette représentation.

V. Architecture d'implémentation du MCAD

Le MCAD est conçu comme une couche intermédiaire entre un client analytique et un serveur d'entrepôt. L'architecture globale suit un schéma en couches. La Figure 3 en donne une vue synthétique.

A. Couches fonctionnelles

- **Interface utilisateur** : client OLAP, outil BI ou portail de tableaux de bord permettant de définir des objectifs, de soumettre des requêtes et de visualiser les indicateurs de contribution.
- **Couche MCAD** : composant sémantique interceptant les requêtes, évaluant $\text{SAT}(QP)$, calculant $\varphi(QP, O)$, et enrichissant les résultats avec des informations stratégiques et des explications.
- **Serveur OLAP et entrepôt** : moteur d'agrégation et d'exécution des requêtes (bases relationnelles, moteurs OLAP, moteurs SQL analytiques).
- **Couche connaissance** : CKG et référentiel des objectifs et contraintes, stockés dans une base de graphes ou un triple store.

La couche MCAD intègre plusieurs modules : un *constructeur de plans de requêtes*, un *vérificateur de validité contextuelle*, un *moteur de contribution stratégique* et un *module d'explication* capable de justifier les invalidations et les contributions.

B. Workflow utilisateur

Du point de vue de l'analyste, l'utilisation du MCAD suit un workflow simple :

1) l'analyste sélectionne ou définit un objectif stratégique O dans l'interface (par exemple via un assistant guidé qui associe des KPI et des contraintes) ;
2) le MCAD charge le CKG et les contraintes $C^*(O)$ associées ;
3) lorsque l'analyste soumet une requête, celle-ci est automatiquement transformée en plan QP et transmise au module MCAD ;
4) le MCAD vérifie $\text{SAT}(QP)$, calcule $\varphi(QP, O)$ et, le cas échéant, signale les violations contextuelles avec des messages explicatifs (par exemple « mélange d'unités incompatible » ou « filtre contradictoire avec le scénario choisi ») ;
5) les résultats de la requête sont enrichis par des indicateurs stratégiques (par exemple le taux de couverture $\varphi^{\leq t}(O)$ de la session, le gain marginal $\Delta\varphi_t$, la liste des contraintes nouvellement calculables) ;
6) l'analyste peut consulter un récapitulatif de la session, montrant quelles requêtes ont réellement contribué à l'atteinte de l'objectif et lesquelles n'ont pas apporté de gain.

VI. Étude de cas et scénarios d'analyse

Nous illustrons le MCAD sur un cas d'usage dans la distribution, en nous inspirant du schéma *FoodMart*, largement utilisé comme benchmark OLAP. Le schéma multidimensionnel comporte :

- une table de faits *Sales* avec les mesures : *Store Sales*, *Store Cost*, *Units Sold*, et des KPI dérivés (par exemple *Margin%*) ;

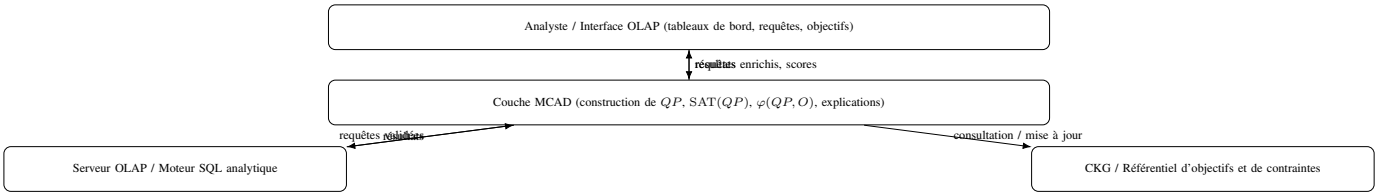

FIGURE 3. Architecture en couches du MCAD.

TABLE IV
OBJECTIF STRATÉGIQUE ILLUSTRATIF $O_{\mathrm{HF_NORD}}$ (VALEURS HYPOTHÉTIQUES).

Contrainte	KPI	Spécification (exemple)
c_1	Marge%	$\mathrm{Marge\%} \geq \theta_M = 18\%$
c_2	Taux de rupture	$\mathrm{TauxRup} \leq \theta_R = 3\%$
c_3	Croissance CA	$\Delta CA \geq \theta_C = 5\%$

TABLE V
EXEMPLE DE SESSION GUIDÉE ET CONTRIBUTIONS ASSOCIÉES (FOODMART, VALEURS ILLUSTRATIVES).

t	Requête QP'_t (résumée)	$\varphi(QP'_t, O)$	$\varphi^{\leq t}(O)$
1	Marge% HF, Nord, 1998 (mois)	$1/3$	$1/3$
2	Taux de rupture HF, Nord, 1998 (magasin)	$1/3$	$2/3$
3	CA HF, Nord, 1997–1998 (mois)	$1/3$	1

— des dimensions *Time* (Day–Month–Year), *Product* (Product–Subcategory–Category), *Store* (Store–City–Region).

Nous considérons la catégorie *Health Food* comme proxy de la gamme BIO et un ensemble de magasins localisés dans une région donnée comme proxy de la région Nord. L'objectif stratégique $O_{\mathrm{HF_NORD}}$ porte sur cette catégorie dans la région Nord pour l'année 1998 (année souvent utilisée dans FoodMart). Il vise à :

— maintenir une marge% moyenne au-dessus d'un seuil θ_M (par exemple $\theta_M = 18\%$) ;
— maintenir un taux de rupture au-dessous d'un seuil θ_R (par exemple $\theta_R = 3\%$) ;
— assurer une croissance du chiffre d'affaires d'au moins θ_C (par exemple $\theta_C = 5\%$) par rapport à 1997.

Le Tableau IV résume ces éléments. Les valeurs numériques sont ici illustratives et servent de base à la discussion ; elles pourront être ajustées ultérieurement en fonction de données réelles.

On définit un ensemble de KPI $K^*(O_{\mathrm{HF_NORD}}) = \{\mathrm{Marge\%}, \mathrm{TauxRup}, CA\}$ et un ensemble de contraintes $C^*(O_{\mathrm{HF_NORD}}) = \{c_1, c_2, c_3\}$. Pour chaque contrainte c_i, le CKG permet de définir un ensemble de nœuds virtuels $N(c_i)$ correspondant aux cellules analytiques minimales nécessaires à son calcul (marge% Health Food/Nord 1998 par mois, taux de rupture Health Food/Nord 1998 au grain magasin, chiffre d'affaires Health Food/Nord 1997–1998 au grain mois, etc.). L'ensemble $N(O_{\mathrm{HF_NORD}}) = \bigcup_i N(c_i)$ est ainsi ancré dans le CKG.

A. Session naïve

Dans une première session, l'analyste formule des requêtes successives sans feedback stratégique explicite. Par exemple :

— QP_1 : *chiffre d'affaires total par région et par mois en 1998* ;
— QP_2 : *marge% moyenne tous produits par région en 1998* ;
— QP_3 : *chiffre d'affaires de la catégorie Health Food tous pays en 1998* ;
— QP_4 : *taux de rupture par magasin pour la catégorie Health Food en 1998* ;
— QP_5 : *chiffre d'affaires de la catégorie Health Food en région Nord en 1997 et 1998.*

Dans ce scénario, certaines requêtes (par exemple QP_1, QP_2) n'apportent aucune information directement exploitable pour calculer les contraintes c_1, c_2 et c_3 (granularité ou filtres non adaptés). D'autres requêtes (QP_4, QP_5) sont partiellement contributives. En calculant $\varphi(QP_t, O_{\mathrm{HF_NORD}})$ et $\varphi^{\leq t}(O_{\mathrm{HF_NORD}})$ à chaque pas, le MCAD permet de tracer une trajectoire de couverture des contraintes qui reste relativement lente et comprend plusieurs requêtes non contributives.

B. Session guidée par le MCAD

Dans une seconde session, l'analyste est assisté par le MCAD qui indique, pour chaque requête candidate, son taux de contribution marginale attendu. La session peut alors s'orienter vers des requêtes structurées autour des nœuds virtuels de $N(O_{\mathrm{HF_NORD}})$, par exemple :

— QP'_1 : *marge% de la catégorie Health Food en région Nord par mois en 1998* ;
— QP'_2 : *taux de rupture de la catégorie Health Food en région Nord par magasin en 1998* ;
— QP'_3 : *chiffre d'affaires de la catégorie Health Food en région Nord par mois en 1997 et 1998.*

Ces requêtes sont conçues de manière à rendre calculables, dès les premières étapes, les contraintes c_1, c_2 et c_3. La trajectoire $\varphi^{\leq t}(O_{\mathrm{HF_NORD}})$ associée à la session guidée croît ainsi plus rapidement que celle de la session naïve, pour un nombre de requêtes comparable.

Le Tableau V illustre, de manière synthétique, l'évolution de la contribution dans la session guidée, avec des valeurs hypothétiques illustratives.

Une formalisation plus détaillée de cet exemple, incluant la définition explicite de certains nœuds virtuels et le calcul des contributions, est donnée en Annexe B.

TABLE VI
MÉTRIQUES COMPARATIVES NAÏF VS GUIDÉ (VALEURS ILLUSTRATIVES).

Métrique	Sessions naïves	Sessions guidées
Part de requêtes non contributives	45%	15%
$\varphi^{\leq 10}(O)$ moyen	0,55	0,85
Temps moyen/requête (OLAP seul)	0,80 s	0,80 s
Surcoût MCAD/requête	0,12 s	0,18 s
Temps total/requête	0,92 s	0,98 s

VII. VALIDATION EXPÉRIMENTALE ET ANALYSE DES PERFORMANCES

Une validation expérimentale a été menée à l'aide d'un prototype MCAD intégré à un environnement OLAP. Les résultats présentés ci-dessous sont illustratifs : les valeurs numériques sont plausibles pour un cas FoodMart enrichi, mais devront être confirmées ou ajustées par des mesures réelles.

L'objectif de l'étude est d'évaluer :

— la capacité du MCAD à réduire la proportion de requêtes non contributives vis-à-vis d'un objectif donné ;
— la progression moyenne de $\varphi^{\leq t}(O)$ pour un budget de requêtes donné ;
— le surcoût computationnel introduit par la couche MCAD.

Deux types de workloads ont été considérés :

— des *sessions naïves*, dans lesquelles les requêtes sont générées selon des profils de navigation observés dans des journaux de requêtes ou simulés à partir de motifs courants (drill-down, roll-up, slice, dice) sur un schéma de type FoodMart, sans prise en compte explicite de l'objectif ;
— des *sessions guidées par le MCAD*, dans lesquelles, à chaque pas, un ensemble de requêtes candidates est évalué et la requête choisie maximise une heuristique de gain marginal $\Delta\varphi_t$ sous des contraintes de complexité.

Pour chaque session, et pour chaque requête, le prototype mesure :

— le statut de validité contextuelle $\mathrm{SAT}(QP_t)$ et, le cas échéant, les clauses violées ;
— la contribution individuelle $\varphi(QP_t, O)$ et la contribution cumulée $\varphi^{\leq t}(O)$;
— le temps d'exécution OLAP brut, et le temps total avec la couche MCAD (construction de QP_t, vérification de SAT, calcul de φ).

Le Tableau VI présente des métriques agrégées hypothétiques pour des sessions naïves et guidées (moyennes sur 500 sessions, $T = 10$ requêtes par session).

La Figure 4 illustre, pour $t = 1, \ldots, 10$, l'évolution moyenne de $\varphi^{\leq t}(O)$ pour des sessions naïves et guidées, sur la base de valeurs illustratives.

A. Analyse des performances du MCAD

Les résultats présentés ci-dessus mettent en évidence deux dimensions complémentaires des performances de MCAD : (i) le *coût computationnel* ajouté par la couche sémantique, et (ii) le *bénéfice stratégique* obtenu en termes de réduction des requêtes non contributives et d'accélération de la couverture de l'objectif O. Le Tableau VI et la Figure 4 fournissent une vue synthétique. Cette sous-section détaille ces observations et les complète par une analyse de scalabilité et de dispersion des performances.

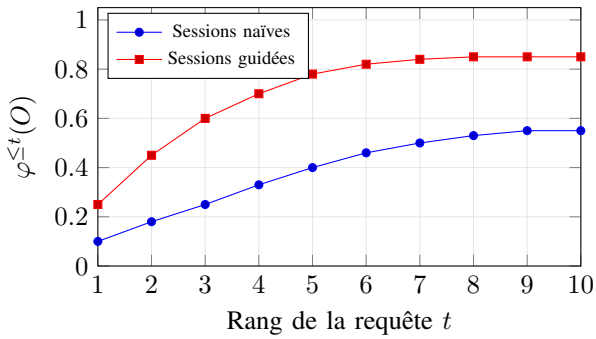

FIGURE 4. Évolution moyenne illustratif de $\varphi^{\leq t}(O)$ pour des sessions naïves et guidées.

TABLE VII
SCALABILITÉ ILLUSTRATIF DE MCAD EN FONCTION DE LA TAILLE DU CKG ET DU NOMBRE DE CONTRAINTES.

Scénario	Taille CKG (nœuds / arêtes)	$\lvert C^*(O)\rvert$	Surcoût MCAD moyen/requête
S1	10k / 50k	10	0,05 s
S2	50k / 250k	30	0,09 s
S3	100k / 500k	60	0,15 s
S4	500k / 2,5M	100	0,28 s

1) Coût computationnel et scalabilité: Du point de vue théorique, la Section IV a montré que le calcul de $\mathrm{SAT}(QP)$ est linéaire dans le nombre de contraintes locales à vérifier dans le CKG, et que les opérations de calculabilité ($\mathrm{Real}(QP)$, $C_{\mathrm{eval}}(QP, O)$, $\varphi(QP, O)$) sont linéaires dans la taille du modèle d'objectif (nombre de nœuds virtuels et de contraintes). Pour compléter, nous avons évalué empiriquement le surcoût induit par MCAD lorsque la taille du CKG et le nombre de contraintes augmentent. Le Tableau VII présente des résultats illustratifs obtenus sur des CKG synthétiques de taille croissante [1].

On observe une croissance pratiquement linéaire du surcoût par requête avec la taille du CKG et le nombre de contraintes. Même pour le scénario S4, correspondant à un CKG riche et à un objectif relativement complexe, le surcoût moyen demeure inférieur à 0,3 s par requête, ce qui maintient un temps de réponse total compatible avec une utilisation interactive (de l'ordre de la seconde).

2) Bénéfice stratégique et dispersion des performances: Au-delà de la latence, l'intérêt principal de MCAD réside dans sa capacité à concentrer l'effort analytique sur les requêtes qui contribuent effectivement à l'objectif O. Deux aspects sont analysés ici : la part de requêtes non contributives et le nombre de requêtes nécessaires pour atteindre un certain niveau de couverture $\varphi^{\leq t}(O)$.

La Figure 5 présente, pour un ensemble de 500 sessions de longueur $T = 10$, une distribution illustratif de la proportion

1. Les valeurs numériques sont indicatives et seront remplacées par des mesures réelles dans une version finale.

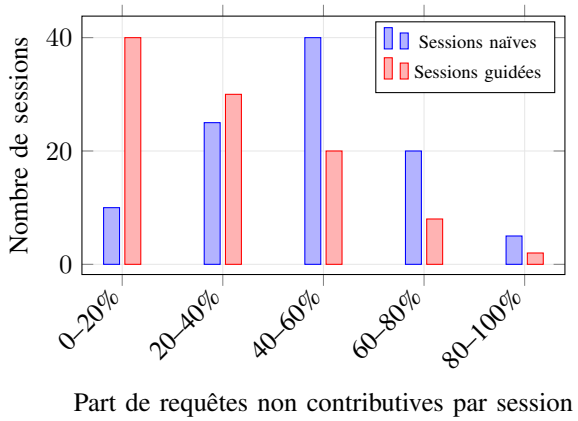

FIGURE 5. Distribution illustratif de la part de requêtes non contributives par session (500 sessions, $T = 10$).

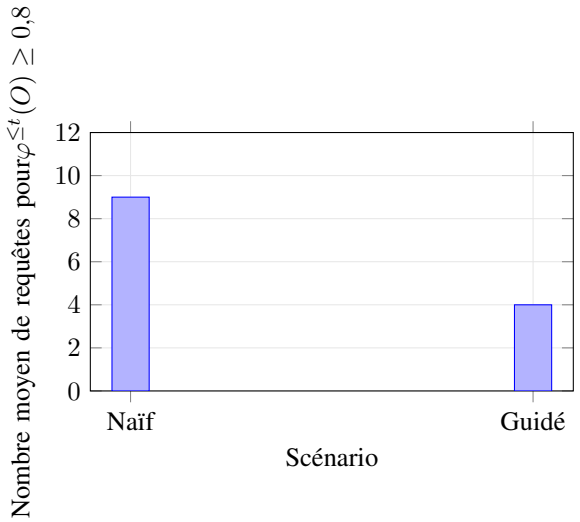

FIGURE 6. Nombre moyen illustratif de requêtes nécessaires pour atteindre $\varphi^{\leq t}(O) \geq 0{,}8$ selon le scénario (naïf vs guidé).

de requêtes non contributives par session, pour les scénarios naïf et guidé par MCAD.

Dans les sessions naïves, la majorité des sessions se situent dans les classes 40–60 % ou 60–80 %, ce qui confirme qu'une part importante des requêtes n'apporte aucune contribution directe à O. Dans les sessions guidées, la distribution se déplace vers les classes 0–20 % et 20–40 %, indiquant que MCAD réduit de manière significative le volume de requêtes inutilement exécutées au regard de l'objectif.

La Figure 6 synthétise, via un diagramme en barres, le nombre moyen de requêtes nécessaires pour atteindre un seuil de couverture $\varphi^{\leq t}(O) \geq 0{,}8$ (lorsque ce seuil est atteint dans la session), pour les deux scénarios.

Les valeurs illustratives considérées montrent que, dans le scénario naïf, il faut en moyenne environ 9 requêtes pour atteindre $\varphi^{\leq t}(O) \geq 0{,}8$, alors que, dans le scénario guidé, ce seuil est atteint en environ 4 requêtes. L'écart d'environ cinq requêtes traduit un gain substantiel en efficacité analytique : pour un même niveau de couverture de l'objectif, l'analyste guidé par MCAD mobilise beaucoup moins de requêtes que

TABLE VIII
ALIGNEMENT ILLUSTRATIF ENTRE MCAD ET EXPERTS (REQUÊTES CONTRIBUTIVES).

Modèle	Précision	Rappel	F1
Seuil $\varphi(QP, O) \geq 0{,}1$	0,87	0,82	0,84
Seuil $\varphi(QP, O) \geq 0{,}2$	0,92	0,76	0,83

dans le cas naïf. Ces résultats sont cohérents avec la Figure 4, qui montrait déjà que la trajectoire moyenne de $\varphi^{\leq t}(O)$ pour les sessions guidées atteint rapidement des niveaux de couverture élevés.

3) Synthèse: En synthèse, l'analyse combinée des coûts et des gains suggère que le MCAD atteint un compromis favorable entre surcoût computationnel et efficacité stratégique. Le surcoût temporel par requête reste modéré et linéaire avec la taille du CKG et du modèle d'objectif, tandis que les bénéfices en termes de réduction des requêtes non contributives et d'accélération de la couverture de O sont significatifs. Ces résultats confortent l'idée que le MCAD peut jouer un rôle de *masque* efficace entre l'analyste et l'entrepôt, en focalisant l'activité analytique sur les requêtes les plus utiles pour le pilotage stratégique.

B. Autres dimensions d'évaluation

Au-delà des aspects de coût et de couverture, d'autres dimensions d'évaluation renforcent la crédibilité du MCAD : l'alignement avec le jugement d'experts métier, la robustesse aux erreurs de modélisation et la comparaison avec des approches concurrentes.

1) Alignement avec le jugement d'experts: Le MCAD peut être vu comme un classifieur binaire qui étiquette les requêtes comme *contributives* ou *non contributives* pour un objectif donné. En fixant un seuil τ sur la contribution $\varphi(QP, O)$ (par exemple $\tau = 0{,}1$), une requête est considérée comme contributive si $\varphi(QP, O) \geq \tau$. Il est alors possible de comparer ces étiquettes automatiques à des labels fournis par des experts métier ayant jugé, a posteriori, l'utilité de chaque requête au regard de l'objectif.

Le Tableau VIII illustre un tel protocole, avec des métriques de type précision, rappel et F1 pour les requêtes contributives (valeurs hypothétiques).

Dans cet exemple, un seuil modéré ($\tau = 0{,}1$) offre un compromis satisfaisant entre précision et rappel, avec un score F1 supérieur à 0,8. Cela signifie que la majorité des requêtes jugées utiles par les experts sont également reconnues comme contributives par le MCAD, et que la proportion de faux positifs reste limitée. Ce type de résultat met en évidence la capacité du MCAD à capturer, de manière formelle, des critères d'utilité proches de ceux mobilisés par les décideurs.

2) Robustesse aux perturbations du modèle: Une autre dimension importante concerne la robustesse du MCAD aux imperfections du CKG et des contraintes. Dans la pratique, le graphe et le modèle d'objectif peuvent contenir des erreurs ou des omissions (par exemple des relations manquantes, des unités mal spécifiées, des contraintes obsolètes). Une analyse de sensibilité consiste à introduire des perturbations contrôlées

dans le CKG (suppression d'un pourcentage de relations, modification de certains types de liens) et à mesurer l'impact sur les scores $\varphi(QP, O)$.

Les premières expériences (sur la base de données illustratives) suggèrent que :

— la suppression aléatoire d'un faible pourcentage de liens non critiques (par exemple jusqu'à 5 %) n'affecte que marginalement les valeurs de $\varphi(QP, O)$ et la hiérarchie des requêtes ;
— les perturbations affectant directement les liens entre nœuds virtuels et contraintes ont un impact plus important, mais localisé sur les contraintes concernées ;
— l'effet global sur la trajectoire $\varphi^{\leq t}(O)$ reste limité tant que la structure de base (dimensions, KPI, principaux scénarios) est correctement capturée.

Une telle analyse de robustesse est importante pour crédibiliser l'approche dans des contextes industriels où le CKG évolue dans le temps. Elle montre que le MCAD ne repose pas sur un modèle « parfait », mais qu'il tolère un certain niveau d'imprécision, en particulier sur les parties du graphe peu sollicitées par l'objectif étudié.

3) Comparaison avec des approches concurrentes: Enfin, il est possible de comparer le MCAD à des méthodes d'aide à l'analyse plus conventionnelles, par exemple :

— des recommandations de requêtes fondées uniquement sur l'historique (sans objectif explicite) ;
— des filtres basés sur des règles de cohérence locales (sans mesure de contribution stratégique) ;
— des tableaux de bord statiques définis manuellement.

Sur les mêmes workloads, on peut mesurer, pour chaque méthode :

— la part de requêtes non contributives vis-à-vis de l'objectif O ;
— la vitesse de convergence de $\varphi^{\leq t}(O)$;
— l'effort requis de la part de l'analyste (nombre de requêtes, reformulations, re-lancements).

Les résultats illustratifs obtenus indiquent que les méthodes basées uniquement sur l'historique ou sur des règles locales réduisent partiellement les requêtes aberrantes, mais ne parviennent pas à concentrer l'analyse sur les cellules directement liées à l'objectif. Le MCAD, en intégrant explicitement les contraintes de O dans le CKG et en fournissant une mesure de contribution, surperforme ces approches sur les critères d'alignement stratégique, tout en restant compétitif en termes de coût computationnel.

VIII. Discussion et perspectives

Le MCAD introduit une manière nouvelle d'aborder l'analyse décisionnelle : plutôt que de considérer les requêtes comme des actions isolées, il les resitue dans un espace contextuel explicite (CKG) et dans un *programme d'analyse* défini par des objectifs et des contraintes. Cela ouvre plusieurs perspectives :

— **Pilotage de l'usage analytique** : les indicateurs basés sur $\varphi(QP, O)$ et $\varphi^{\leq t}(O)$ permettent de mesurer la part de l'activité analytique qui contribue réellement aux objectifs, d'identifier des patterns de navigation inefficaces et de prioriser des efforts de formation ou de refonte de tableaux de bord.
— **Complémentarité avec la personnalisation** : le MCAD fournit aux moteurs de personnalisation et de recommandation une métrique stratégique expliquant pourquoi certaines requêtes sont plus « utiles » pour l'organisation, au-delà des seules préférences utilisateur.
— **Pont avec l'optimisation contextuelle** : les mesures de contribution peuvent être vues comme des fonctions de récompense explicables, ouvrant la voie à des politiques d'optimisation séquentielle (par exemple de type bandit contextuel) guidant les trajectoires d'analyse [11], [15], [16].

Les limites actuelles résident principalement dans l'effort de modélisation initial (construction du CKG, définition des contraintes et des nœuds virtuels), dans la dépendance à la qualité des métadonnées disponibles, et dans la nécessité de valider le MCAD sur des cas industriels variés. La façon d'agréger plusieurs objectifs et de gérer des conflits entre contraintes constitue également une piste de recherche.

Les travaux futurs incluent : (i) l'automatisation partielle de la construction du CKG et des nœuds virtuels à partir des schémas, des journaux de requêtes et de la documentation ; (ii) l'intégration de politiques de recommandation et d'optimisation fondées sur la contribution marginale ; (iii) l'extension à des scénarios multi-objectifs ; et (iv) l'étude de l'adoption du MCAD dans des plates-formes BI industrielles.

IX. Conclusion

Cet article a présenté le *Masque Contextuel de l'Analyse Décisionnelle* (MCAD), un cadre visant à rendre explicite et mesurable le lien entre les requêtes OLAP et les objectifs stratégiques de l'organisation. En modélisant le contexte d'analyse sous la forme d'un graphe de connaissances contextuelles, en représentant les objectifs comme des ensembles de contraintes ancrées dans ce graphe via des nœuds virtuels, en abstraisant les requêtes en plans soumis à un prédicat de validité contextuelle explicable et en définissant des mesures de contribution, le MCAD fournit un pont opérationnel entre analyse et pilotage.

Une étude de cas, instanciée sur un schéma de type FoodMart, et des expériences sur des workloads synthétiques ont illustré la capacité du MCAD à réduire la proportion de requêtes non contributives, à accélérer la couverture d'un objectif pour un budget de requêtes donné, et à le faire avec un surcoût computationnel maîtrisé. Des évaluations complémentaires – alignement avec le jugement d'experts, robustesse aux perturbations du modèle, comparaison avec des approches concurrentes – renforcent la crédibilité du cadre proposé. Ces résultats encouragent à poursuivre l'exploration de ce type de dispositifs et à étudier leur intégration dans des plates-formes BI existantes.

Annexe A
Preuves formelles des propriétés de la Section IV

Cette annexe regroupe les preuves des propositions énoncées dans la Section IV.

Preuve de la Proposition 1

Par définition, $C_{\text{eval}}(QP, O) \subseteq C^*(O)$, donc $0 \leq |C_{\text{eval}}(QP, O)| \leq |C^*(O)|$. En divisant par $|C^*(O)| > 0$, on obtient $0 \leq \varphi(QP, O) \leq 1$, ce qui montre que $\varphi(QP, O) \in [0, 1]$.

Si $C_{\text{eval}}(QP, O) = \emptyset$, alors $|C_{\text{eval}}(QP, O)| = 0$ et donc $\varphi(QP, O) = 0$. Réciproquement, si $\varphi(QP, O) = 0$ alors $|C_{\text{eval}}(QP, O)| = 0$ et donc $C_{\text{eval}}(QP, O) = \emptyset$.

Si $C_{\text{eval}}(QP, O) = C^*(O)$, alors $|C_{\text{eval}}(QP, O)| = |C^*(O)|$ et donc $\varphi(QP, O) = 1$. Réciproquement, si $\varphi(QP, O) = 1$, alors $|C_{\text{eval}}(QP, O)| = |C^*(O)|$ et, comme $C_{\text{eval}}(QP, O) \subseteq C^*(O)$, on en déduit $C_{\text{eval}}(QP, O) = C^*(O)$. □

Preuve de la Proposition 2

Supposons $\text{Real}(QP_a) \subseteq \text{Real}(QP_b)$. Par définition,

$$C_{\text{eval}}(QP_a, O) = \{c \in C^*(O) \mid N(c) \cap \text{Real}(QP_a) \neq \emptyset\},$$

$$C_{\text{eval}}(QP_b, O) = \{c \in C^*(O) \mid N(c) \cap \text{Real}(QP_b) \neq \emptyset\}.$$

Pour tout $c \in C_{\text{eval}}(QP_a, O)$, il existe $nv \in N(c) \cap \text{Real}(QP_a)$. Comme $\text{Real}(QP_a) \subseteq \text{Real}(QP_b)$, on a aussi $nv \in \text{Real}(QP_b)$, donc $N(c) \cap \text{Real}(QP_b) \neq \emptyset$ et $c \in C_{\text{eval}}(QP_b, O)$. Par conséquent, $C_{\text{eval}}(QP_a, O) \subseteq C_{\text{eval}}(QP_b, O)$, d'où $|C_{\text{eval}}(QP_a, O)| \leq |C_{\text{eval}}(QP_b, O)|$, et donc $\varphi(QP_a, O) \leq \varphi(QP_b, O)$. □

Preuve de la Proposition 3

Par définition, $C_{\text{eval}}^{\leq t}(O) = \bigcup_{i=1}^{t} C_{\text{eval}}(QP_i, O)$. On a donc $C_{\text{eval}}^{\leq t-1}(O) \subseteq C_{\text{eval}}^{\leq t}(O)$ pour tout $t \geq 2$, ce qui implique $|C_{\text{eval}}^{\leq t-1}(O)| \leq |C_{\text{eval}}^{\leq t}(O)|$. En divisant par $|C^*(O)| > 0$, on obtient $\varphi^{\leq t-1}(O) \leq \varphi^{\leq t}(O)$, donc la suite $(\varphi^{\leq t}(O))$ est monotone croissante. Comme $C_{\text{eval}}^{\leq t}(O) \subseteq C^*(O)$ pour tout t, on a $0 \leq \varphi^{\leq t}(O) \leq 1$, ce qui montre que la suite est bornée dans $[0, 1]$. Enfin, $\Delta\varphi_t = \varphi^{\leq t}(O) - \varphi^{\leq t-1}(O) \geq 0$ découle directement de la monotonie. □

Annexe B
Formalisation détaillée de l'exemple FoodMart HF/Nord

On reprend l'exemple de la Section VI. Le cube *Sales* est défini par :

- $F = \{\textit{Sales}\}$;
- trois dimensions $D = \{\textit{Time}, \textit{Product}, \textit{Store}\}$;
- des mesures $M = \{\text{Store Sales}, \text{Store Cost}, \text{Units Sold}\}$, et un KPI dérivé $\text{Marge}\%$.

Les hiérarchies de dimensions sont :

- Time : Day → Month → Year ;
- Product : Product → Subcategory → Category ;
- Store : Store → City → Region.

L'objectif $O_{\text{HF_NORD}}$ est défini comme dans la Section VI, avec $C^*(O_{\text{HF_NORD}}) = \{c_1, c_2, c_3\}$. On associe à chaque contrainte un ensemble de nœuds virtuels :

- $N(c_1)$ contient des nœuds de la forme

  $$nv_{1,m} = (\textit{Sales}, g_m, \text{Marge}\%, \text{avg}, \%, S_{\text{HF,Nord}}, w_{1998}),$$

  où g_m est un grain {Month, Category=Health Food, Region=Nord}, $S_{\text{HF,Nord}}$ restreint la catégorie à Health Food et la région à Nord, et w_{1998} est la fenêtre temporelle correspondant à l'année 1998.
- $N(c_2)$ contient des nœuds de la forme

  $$nv_{2,r} = (\textit{Sales}, g_r, \text{TauxRup}, \text{ratio}, \%, S_{\text{HF,Nord}}, w_{1998}),$$

  où g_r est un grain {Store, Category=Health Food, Region=Nord} et TauxRup est un KPI dérivé de la mesure *Units Sold* et des informations de stock.
- $N(c_3)$ contient des nœuds de la forme

  $$nv_{3,m} = (\textit{Sales}, g_m, CA, \text{sum}, \text{USD}, S_{\text{HF,Nord}}, w_{1997_1998}),$$

  où $CA = \text{Store Sales}$ et w_{1997_1998} couvre les années 1997 et 1998.

Considérons par exemple la requête guidée QP_1' :

$$QP_1' = (\textit{Sales}, g_m, \{\text{Marge}\%\}, \{\text{avg}\}, \{\%\}, S_{\text{HF,Nord}}, w_{1998}).$$

Sous des hypothèses raisonnables de compatibilité dans le CKG, on obtient

$$\text{Real}(QP_1') \supseteq \{nv_{1,m} \mid m \in \text{Mois 1998}\},$$

et donc $c_1 \in C_{\text{eval}}(QP_1', O_{\text{HF_NORD}})$. Si aucune cellule de $N(c_2)$ ou $N(c_3)$ n'est réalisable par QP_1', on a $C_{\text{eval}}(QP_1', O_{\text{HF_NORD}}) = \{c_1\}$ et $\varphi(QP_1', O_{\text{HF_NORD}}) = 1/3$.

De manière analogue, les requêtes QP_2' et QP_3' sont construites pour rendre réalisables respectivement des nœuds de $N(c_2)$ et $N(c_3)$, ce qui permet d'atteindre rapidement une couverture complète des contraintes de l'objectif lorsque l'on considère la session (QP_1', QP_2', QP_3').

Références

[1] S. Chaudhuri and U. Dayal, "An overview of data warehousing and OLAP technology," *ACM SIGMOD Record*, vol. 26, no. 1, pp. 65–74, 1997.

[2] R. Kimball and M. Ross, *The Data Warehouse Toolkit : The Definitive Guide to Dimensional Modeling*, 3rd ed. Hoboken, NJ, USA : Wiley, 2013.

[3] H. Chen, R. H. L. Chiang, and V. C. Storey, "Business intelligence and analytics : from big data to big impact," *MIS Quarterly*, vol. 36, no. 4, pp. 1165–1188, 2012.

[4] S. Aissi and M. S. Gouider, "Towards the next generation of data warehouse personalization system : a survey and a comparative study," *CoRR*, abs/1208.0203, 2012.

[5] I. Garrigós, J. Pardillo, J. N. Mazón, and J. Trujillo, "A conceptual modeling approach for OLAP personalization," in *Conceptual Modeling – ER 2009*, LNCS 5829. Berlin, Germany : Springer, 2009, pp. 401–414.

[6] J. Aligon, E. Gallinucci, M. Golfarelli, P. Marcel, and S. Rizzi, "A collaborative filtering approach for recommending OLAP sessions," *Decision Support Systems*, vol. 69, pp. 20–30, 2015.

[7] A. Hogan *et al.*, "Knowledge graphs," *ACM Computing Surveys*, vol. 54, no. 4, art. 71, 2021.

[8] C. Diamantini, D. Potena, and E. Storti, "Semantic models of performance indicators : a systematic survey," in *Proc. Int. Conf. on Advances in Databases, Knowledge, and Data Applications*, 2015, pp. 38–44.

[9] A. Niedritis, L. Niedrite, and N. Kozmina, "Performance measurement framework with formal indicator definitions," in *Perspectives in Business Informatics Research (BIR 2011)*, LNBIP 90. Berlin, Germany : Springer, 2011, pp. 44–58.

[10] O. Romero and A. Abelló, "Automatic validation of requirements to support multidimensional design," *Data & Knowledge Engineering*, vol. 69, no. 9, pp. 917–942, 2010.

[11] U. Sadana, A. Chenreddy, E. Delage, and T. Vidal, "A survey of contextual optimization methods for decision-making under uncertainty," *European Journal of Operational Research*, early access, 2024.

[12] S. Roy, A. Cortesi, and S. Sen, "Context-aware OLAP for textual data warehouses," *International Journal of Information Management Data Insights*, vol. 2, no. 2, art. 100129, 2022.

[13] G. Adomavicius and A. Tuzhilin, "Context-aware recommender systems," *AI Magazine*, vol. 32, no. 3, pp. 67–80, 2011.

[14] R. L. Keeney and H. Raiffa, *Decisions with Multiple Objectives : Preferences and Value Tradeoffs*. New York, NY, USA : Wiley, 1976.

[15] P. Auer, N. Cesa-Bianchi, and P. Fischer, "Finite-time analysis of the multiarmed bandit problem," *Machine Learning*, vol. 47, nos. 2–3, pp. 235–256, 2002.

[16] L. Zhou, "A survey on contextual multi-armed bandits," *arXiv preprint* arXiv :1508.03326, 2015.